

30 特征值和奇异值

30.1 特征值和奇异值定义

在多元统计和时间序列分析中会用到特征值和奇异值, 比如, 主成分分析、典型相关分析、对应分析、多元自回归模型等。

先简单回顾线性代数中特征值的定义和性质。设 A 为 n 阶方阵, 若有非零向量 α 和复数 λ 使得

$$A\alpha = \lambda\alpha,$$

则称 λ 是矩阵 A 的一个**特征值**, α 是特征值 λ 对应的**特征向量**。特征向量具有某种不变性: 矩阵 A 左乘特征向量, 不改变特征向量的方向 (没有正反)。

当 A 为 n 阶实对称阵时, A 恰有 n 个实特征值, 记作 $\lambda_1, \lambda_2, \dots, \lambda_n$, 相应的特征向量也都是实向量, 且存在 n 阶正交阵 U 使得

$$A = U\Lambda U^T = \sum_{j=1}^n \lambda_j \mathbf{u}_{\cdot j} \mathbf{u}_{\cdot j}^T,$$

其中 $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ 是对角线元素为 A 的特征值的对角阵, U 的第 j 列 $\mathbf{u}_{\cdot j}$ 是 λ_j 对应的特征向量。

当 A 为非负定阵时, 所有特征值非负; 当 A 为正定阵时, 所有特征值都是正数。 A 为非负定阵时, 令 $\Lambda^{1/2} = \text{diag}(\lambda_1^{1/2}, \lambda_2^{1/2}, \dots, \lambda_n^{1/2})$, 令 $A^{1/2} = U\Lambda^{1/2}U^T$, 则

$$(A^{1/2})^2 = U\Lambda^{1/2}U^T U\Lambda^{1/2}U^T = U\Lambda^{1/2}\Lambda^{1/2}U^T = U\Lambda U^T = A.$$

如果 A 是对称阵且 $\lambda_1, \dots, \lambda_n$ 中仅有 $\lambda_1, \dots, \lambda_r$ 绝对值较大, 其余特征值接近于零, 则矩阵 A 有如下的近似:

$$A \approx \sum_{j=1}^r \lambda_j \mathbf{u}_{\cdot j} \mathbf{u}_{\cdot j}^T,$$

在统计问题如典型相关分析中还会遇到广义的特征值问题: 设 A, B 为 n 阶方阵, 若有复数 λ 和非零向量 α 使得

$$A\alpha = \lambda B\alpha,$$

则称 λ 和 α 分别为矩阵 A 相对于矩阵 B 的**广义特征值**和**广义特征向量**。实际问题中, B 通常是正定阵, A 是实对称阵, 这时(30.3)等价于 $B^{-1}A\alpha = \lambda\alpha$, 可以化为普通特征值问题, 并可利用Cholesky分解进行计算。设 B 有Cholesky分解 $B = LL^T$, 则由 $A\alpha = \lambda LL^T\alpha$ 得 $L^{-1}A(L^T)^{-1}(L^T\alpha) = \lambda(L^T\alpha)$, 求解普通特征值问题 $(L^{-1}A(L^T)^{-1})\beta = \lambda\beta$ 得 λ 和 β 再求解 $L^T\alpha = \beta$ 即可得广义特征值和广义特征向量。

对 n 阶非奇异矩阵 A , 必存在 n 阶正交阵 U 和 V , 使得

$$A = V\text{diag}(d_1, d_2, \dots, d_n)U^T,$$

其中 d_1, d_2, \dots, d_n 是正定阵 $A^T A$ 的 n 个特征值的算术平方根, 称(30.4)为矩阵 A 的**奇异值分解**, d_1, d_2, \dots, d_n 称为 A 的**奇异值**。

若 A 是一般的 $n \times m$ 非零矩阵, A 的秩为 $\text{rank}(A) = r \leq \min(n, m)$, $A^T A$ 的非零特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0$, 令 $d_i = \sqrt{\lambda_i}$, $i = 1, 2, \dots, r$, 则称 d_i 为 A 的**奇异值**, 且一定有 m 阶正交阵 U 和 n 阶正交阵 V 使得

$$A = VDU^T,$$

其中

$$D = \begin{pmatrix} \text{diag}(d_1, d_2, \dots, d_r) & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{pmatrix}_{n \times m},$$

称(30.5)为 A 的**奇异值分解**(singular value decomposition, SVD)。可以看出

$$A = \sum_{i=1}^r d_i v_i u_i^T.$$

当 r 比较小或者奇异值中仅有少数几个较大而其它奇异值都接近于零时, 可以近似 A 为

$$A \approx \sum_{i=1}^{r'} d_i v_i u_i^T.$$

其中 r' 远小于 $\max(n, m)$ 。

详见 高惠璇 (1995) §5.4 和 Monahan (2001) §6.6。

30.2 对称阵特征值分解的Jacobi算法

矩阵 A 的特征值 λ 是 A 的特征多项式 $A - \lambda I$ 的根, 但直接求多项式的根并不容易, 特征值和特征向量的计算一般都通过迭代算法实现。

Loading [MathJax]/extensions/MathEvents.js

§29.3引入的Givens变换是一个旋转变换，可以仅改变向量中指定的两个元素并使得第二个指定元素变成零。类似这样仅改变向量中第 i, j 两个元素的旋转变换矩阵可以写成

$$G_{ij}(\theta) = \begin{pmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & & & \\ & & & \cos \theta & & \sin \theta \\ & & & & 1 & \\ & & & & & \ddots \\ & & & & & & 1 \\ & & & -\sin \theta & & \cos \theta & & \\ & & & & & & & 1 \\ & & & & & & & & \ddots \\ & & & & & & & & & 1 \end{pmatrix}.$$

若 A 为对称阵，适当选取角度 θ 对 A 作如下变换

$$A^* = G_{ij}(\theta)A(G_{ij}(\theta))^T$$

可以使得 $a_{ij}^* = a_{ji}^* = 0$ ，这样的变换叫做**Jacobi**变换。对 A 反复地作Jacobi变换可以使得非对角线元素趋于零。

考虑Jacobi变换(30.8)中角度 θ 的确定。显然， A^* 和 A 的不同仅体现在第 i, j 行和第 i, j 列，其它元素保持不变； $G_{ij}(\theta)A$ 与 A 仅在第 i, j 行有差别， $A(G_{ij}(\theta))^T$ 与 A 仅在第 i, j 列有差别， A^* 与 $G_{ij}(\theta)A$ 仅在第 i, j 列有差别。简单推导可得

$$a_{ij}^* = \frac{1}{2}(a_{jj} - a_{ii}) \sin 2\theta + a_{ij} \cos 2\theta,$$

只要取 $\theta \in (-\frac{\pi}{4}, \frac{\pi}{4})$ 使得

$$\tau = \cot 2\theta = \frac{a_{ii} - a_{jj}}{2a_{ij}}$$

即可使 $a_{ij}^* = a_{ji}^* = 0$ 。

注意到 $G_{ij}(\theta)$ 仅依赖于 $\cos \theta$ 和 $\sin \theta$ ，设 $x = \tan \theta$ ，由三角函数公式得

$$x^2 + 2\tau x - 1 = 0.$$

x 有两个根，为保证 $|\theta| \leq \frac{\pi}{4}$ 取其中绝对值较小的一个，为

$$x = \tan \theta = \operatorname{sgn}(\tau)(-|\tau| + \sqrt{\tau^2 + 1}) = \frac{\operatorname{sgn}(\tau)}{|\tau| + \sqrt{\tau^2 + 1}},$$

(其中 $\operatorname{sgn}(\cdot)$ 表示符号函数, 对非负数取1, 对负数取-1)从 $x = \tan \theta$ 再计算出

$$\cos \theta = (1 + x^2)^{-\frac{1}{2}}, \quad \sin \theta = x \cos \theta.$$

这样求 $\cos \theta$ 和 $\sin \theta$ 避免了三角函数计算并且 x 的计算方法考虑到了避免两个相近数相减造成精度损失的问题。

设 A 为实对称阵, J_{ij} 是 A 关于下标 (i, j) 的Jacobi变换阵, 令 $A^* = J_{ij} A J_{ij}^T$, 则 A^* 有如下性质:

- i) A^* 仍为对称阵;
- ii) $a_{ij}^* = a_{ji}^* = 0$, 且对 $k, t \neq i, j$ 有 $a_{kt}^* = a_{kt}$;
- iii) 对 $t \neq i, j$ 有 $(a_{it}^*)^2 + (a_{jt}^*)^2 = a_{it}^2 + a_{jt}^2$;
- iv) $\sum_i \sum_j (a_{ij}^*)^2 = \sum_i \sum_j a_{ij}^2$;
- v) $\operatorname{off}(A^*) = \operatorname{off}(A) - 2a_{ij}^2$, 其中 $\operatorname{off}(A)$ 表示 A 中非对角线元素的平方和。

Jacobi算法从 $A^{(0)} = A$ 和 $U^{(0)} = I_n$ 出发反复作Jacobi变换, 设已有 $A^{(k-1)}$, 则在第 k 步求 $A^{(k-1)}$ 的非对角元素中绝对值最大者, 设为其 (i_k, j_k) 元素, 用(30.9)和(30.10)针对 $A^{(k-1)}$ 和 (i_k, j_k) 求出Jacobi变换矩阵 $J^{(k)}$, 则令 $U^{(k)} = U^{(k-1)}(J^{(k)})^T$, $A^{(k)} = J^{(k)} A^{(k-1)}(J^{(k)})^T$, 如此重复直到 $A^{(k)}$ 的非对角元素的绝对值最大值小于预定的精度 ϵ 。这时有 $A = U \Lambda U^T$, $U = U^{(k)}$ 是正交阵, Λ 近似为对角阵。

可以证明上述Jacobi算法的 $A^{(k)}$ 收敛到一个对角阵且对角线元素为 A 的特征值。此算法收敛较快, 但每次寻找非对角元素中绝对值最大的一个比较耗时。改进的Jacobi算法从 A 和 $U = I$ 出发, 在第 k 步时基于上一步的 A 计算一个界限 $\epsilon_k = \sqrt{\operatorname{off}(A^{(k)})}/[n(n-1)]$, 然后对 A 的每个严格上三角元素都做一次Jacobi变换, 用变换后的矩阵代替原来的 A 并更新矩阵 U , 但是若该严格上三角元素绝对值小于 ϵ_k 就跳过该元素。所有严格上三角元素都处理过一遍才进入第 $k+1$ 步并计算新的 ϵ_{k+1} , 重复运算直到 ϵ_{k+1} 小于预先指定的误差限 ϵ 为止。

在R软件中, 用 `eigen()` 函数计算特征值和特征向量。

30.3 用QR分解方法求对称矩阵特征值分解

计算实对称矩阵特征值分解的一种较好的方法是利用Householder变换和Givens变换。首先, 若 A 为 n 阶实对称矩阵, 可以用 $n-2$ 个Householder变换把它变成对称三对角矩阵: 设 H_1 为一个分块对角矩阵, 主对角线的第一块为1阶单位阵, 第二块是把 A 的第一列最后 $n-1$ 个元素中后 $n-2$ 个元素变成零的Householder变换阵, 则 $H_1 A$ 第一列为 $(a_{11}, a_{21}^{(1)}, 0, \dots, 0)^T$, 其中

Loading [MathJax]/extensions/MathEvents.js

$a_{21}^{(1)} = \sqrt{a_{21}^2 + \cdots + a_{n1}^2}$, 且 $H_1 A$ 的第一行与 A 的第一行完全相同, 于是, $H_1 A H_1$ 的第一行为 $(a_{11}, a_{21}^{(1)}, 0, \dots, 0)^T$, 注意到 H_1 的对称性与正交性, $H_1 A H_1$ 仍为对称阵, 但是第一列和第一行的最后 $n - 2$ 个元素已经变成了零。在第二步, 可以构造一个分块对角矩阵 H_2 , 对角线第一块为 I_2 , 第二块是把矩阵 $H_1 A H_1$ 的第二列中最后 $n - 3$ 个元素变成零的Householder变换矩阵, 把 $H_1 A H_1$ 变成 $H_2 H_1 A H_1 H_2$, 易见第一列和第一行不变, 第二列和第二行的最后 $n - 3$ 个元素变成了零。如此进行下去得到 $A^{(0)} = H_{n-2} \cdots H_1 A H_1 \cdots H_{n-2}$, 使得 $A^{(0)}$ 为三对角对称矩阵。

得到三对角对称矩阵 $A^{(0)}$ 以后, 进行QR迭代。设经过 $k - 1$ 次迭代后得到矩阵 $A^{(k-1)}$, 在第 k 步, 先选一个平移量 t_k , 对矩阵 $A^{(k-1)} - t_k I$ 用Givens变换方法作QR分解得到 $A^{(k-1)} - t_k I = Q_k R_k$, 把得到的上三角阵 R_k 右乘 Q_k 再反向平移, 得到

$$A^{(k)} = R_k Q_k + t_k I = Q_k^T (A^{(k-1)} - t_k I) Q_k + t_k I = Q_k^T A^{(k-1)} Q_k,$$

这样的 $A^{(k)}$ 仍是三对角对称矩阵, 如此迭代直到 $A^{(k)}$ 变成对角形。收敛时, $A^{(k)}$ 的对角线元素为各个特征值, $H_1 \cdots H_{n-2} Q_1 \cdots Q_k$ 的各列为相应特征向量。

具体的算法比较复杂, 详见 Monahan (2001) §6.5, Gentle (2007) §7.4。

30.4 奇异值分解的计算

设 A 为任意非零 $n \times m$ 实值矩阵, 先说明 A 的奇异值分解的存在性。以下用 $\|\cdot\|$ 表示向量的长度, 即 $\|\cdot\|_2$ 。首先, 非负定阵 $A^T A$ 和 $A A^T$ 有共同的正特征值 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$ 且个数 r 为矩阵 A 的秩。设 $\mathbf{u}^{(i)}$ 是 $A^T A$ 的特征值 λ_i 对应的单位特征向量 (长度为1), 则 $A^T A \mathbf{u}^{(i)} = \lambda_i \mathbf{u}^{(i)}$, 由此式可得 $\|A \mathbf{u}^{(i)}\|^2 = \lambda_i$ 。在 $A^T A \mathbf{u}^{(i)} = \lambda_i \mathbf{u}^{(i)}$ 两边左乘矩阵 A 得到 $(A A^T)(A \mathbf{u}^{(i)}) = \lambda_i (A \mathbf{u}^{(i)})$, 即 $A \mathbf{u}^{(i)}$ 是矩阵 $A A^T$ 的对应于特征值 λ_i 的特征向量, 长度为 $d_i = \sqrt{\lambda_i}$ 。设 $A A^T$ 的所有特征向量组成的正交阵为 V , $\mathbf{v}^{(j)}$ 是 V 的第 j 列, 适当构造的 V 可使得

$$\mathbf{v}^{(j)} A \mathbf{u}^{(i)} = d_i \delta_{i-j}, \quad i = 1, 2, \dots, m, \quad j = 1, 2, \dots, n,$$

其中 δ_{i-j} 是Kronecker记号, 当 $i = j$ 时表示1, 当 $i \neq j$ 时表示0, 当 $i > r$ 时令 $d_i = 0$ 。把 (30.11) 式写成矩阵形式即 $V^T A U = D$, $A = V D U^T$ (D 的定义见 (30.6)), 说明任何非零矩阵 A 均有奇异值分解。

以上的证明给出了求奇异值分解的一种方法: 先选 $A^T A$ 和 $A A^T$ 中阶数较低一个, 不妨设是 $A^T A$, 求其特征值分解得到 A 的所有奇异值和矩阵 U , 然后利用上面的关系得到 $A A^T$ 的对应于非零特征值的特征向量, 如果需要再补充适当列向量组成正交方阵 V 即可。这种方法比较简单, 但是计算 $A^T A$ 会造成累积误差。

当 A 为 $n \times m$ 的列满秩矩阵时, 可以用类似§30.3的QR分解方法来求 A 的奇异值分解。方法描述如下。仿照正交三角分解把一个对称矩阵变成三对角矩阵的做法, 我们可以先在 A 的左边乘以 $n - 2$ 个对称正交阵把 A 变成上三角形, 然后在此上三角形矩阵右边乘以 $n - 1$ 个对称正交阵将其变成上双对角阵, 即除对角线和上副对角线外的元素都是零的矩阵。总之, 存在 n 阶正交阵 P 和 m 阶正交阵 Q 使得

$$PAQ = \begin{pmatrix} B_{m \times m} \\ \mathbf{0}_{(n-m) \times m} \end{pmatrix},$$

其中 B 的元素满足当 $i > j$ 或 $j > i + 1$ 时 $b_{ij} = 0$, 且 B 满秩。

得到上双对角阵 B 后, 先求 $B^T B$ 的特征值分解。 $B^T B$ 是一个三对角对称阵, 可以用的QR方法求特征值分解。设 $B^T B = U_1 D_m^2 U_1^T$, 其中 $D_m = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_m})$, $\lambda_1 \geq \dots \geq \lambda_m > 0$ 为 $B^T B$ 的所有特征值, U_1 各列为 $B^T B$ 的特征向量。令 $V_1 = B U_1 D_m^{-1}$, 则 $V_1^T V_1 = I_m$, 于是 $B = V_1 D_m U_1^T$ 是 B 的奇异值分解。

这时,

$$\begin{aligned} PAQ &= \begin{pmatrix} B \\ \mathbf{0} \end{pmatrix} = \begin{pmatrix} V_1 D_m U_1^T \\ \mathbf{0} \end{pmatrix} = \begin{pmatrix} V_1 & \mathbf{0} \\ \mathbf{0} & I_{n-m} \end{pmatrix}_{n \times n} \begin{pmatrix} D_m \\ \mathbf{0} \end{pmatrix}_{n \times m} U_1^T \\ &\triangleq V_2 \begin{pmatrix} D_m \\ \mathbf{0} \end{pmatrix}_{n \times m} U_1^T, \end{aligned}$$

则 V_2 为 n 阶正交阵, 可得 A 有奇异值分解

$$A = (P^T V_2) D (Q U_1)^T \triangleq V D U^T,$$

其中 $V = P^T V_2$ 为 n 阶正交阵, $U = Q U_1$ 为 m 阶正交阵, D 为 $n \times m$ 对角阵, 对角线元素为 $B^T B$ 的特征值的算术平方根。

习题

习题1

编写关于实对称矩阵 A 用Jacobi方法求特征值分解的程序。

习题2

编写关于实对称矩阵 A 用改进的Jacobi方法求特征值分解的程序。

设 A 为 n 阶实对称方阵, 编写程序用正交相似变换 $B = Q A Q$ 把 A 变换为三对角对称矩阵 B , 其中 Q 为 n 阶对称正交阵, 输出 B 和 Q 的值。

习题4

设 n 方阵 A 为上双对角矩阵: 当 $j \neq i, i + 1$ 时总有 $a_{ij} = 0$ 。证明 $B = A^T A$ 为三对角矩阵。

习题5

设 A 为 n 阶非负定对称矩阵, 用拉格朗日乘子法求 $x^T x = 1$ 条件下 $x^T A x$ 的最大值点。

习题6

设 A 为 n 阶非负定对称矩阵, 用 A 的特征值分解求 $x^T x = 1$ 条件下 $x^T A x$ 的最大值点。

References

Gentle, James E. 2007. *Matrix Algebra: Theory, Computations, and Applications in Statistics*. Springer.

Monahan, John F. 2001. *Numerical Methods of Statistics*. Cambridge University Press.

高惠璇. 1995. 统计计算. 北京大学出版社.